ВЫСШАЯ ШКОЛА ЭКОНОМИКИ

Онлайн-встреча

Как машинное обучение меняет онлайн-торговлю

Мария Жарова
Team Lead ML Wildberries & Russ

Спикер



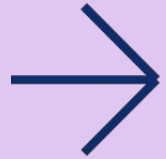
Мария Жарова

- ML-инженер Wildberries & Russ
  Преподаватель ВШЭ, МФТИ, МИФИ, ТГУ
  Автор тг-канала @data_easy
- ex-Data Scientist в Альфа-Банк и Сбер
  Выпускница МФТИ с отличием
- Рекомендательные системы, FinTech
  Публикации по ИИ в российских
  и международных журналах

О чём поговорим?

1. Рекомендательные системы и сценарии их применения
2. Обзор основных подходов и алгоритмов
3. Проблемы и кейсы в рекомендациях

Пишите ваши вопросы в чат!



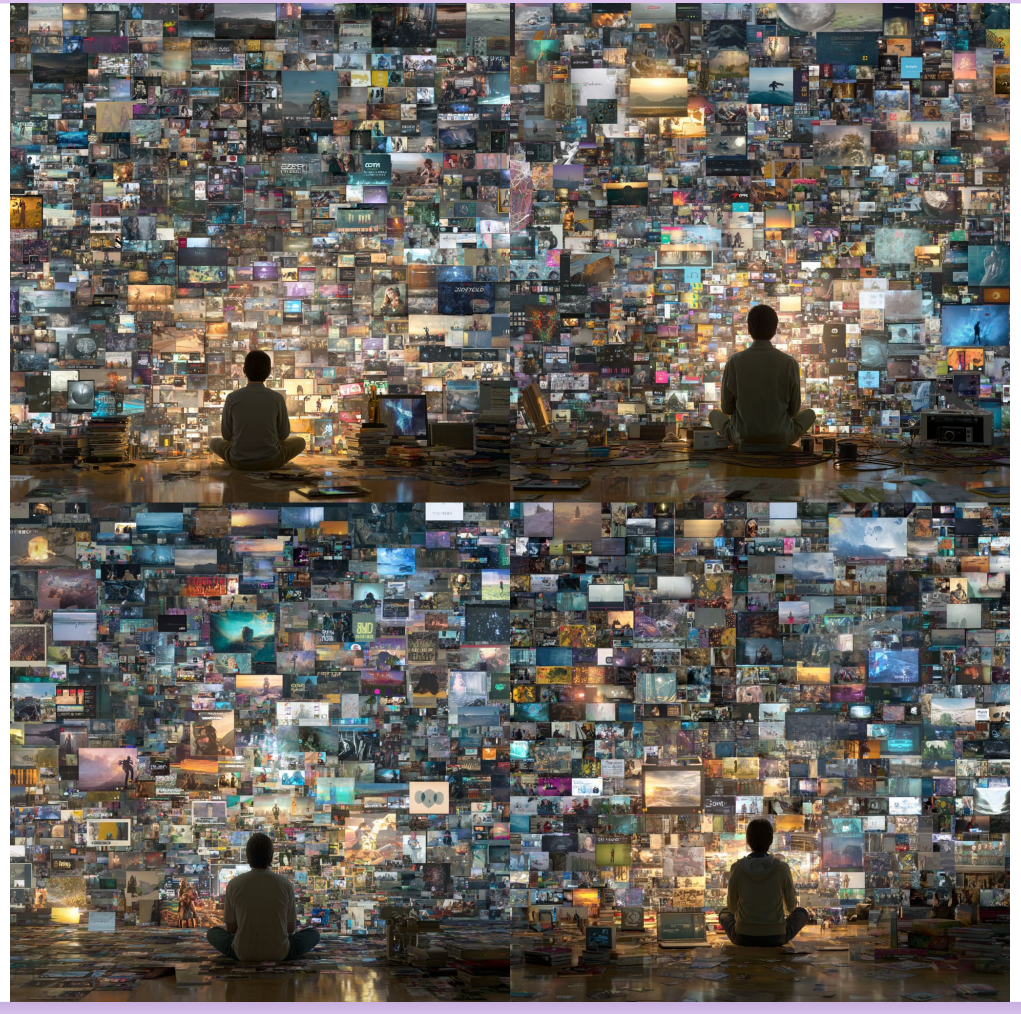
01

Рекомендательные системы и сценарии их применения

Проблема века: паралич выбора

Чем больше вариантов — тем сложнее принять решение.

Цель рекомендательных систем: сократить выбор до релевантного лично вам.



Эксперимент с джемом

Гипотеза исследователей:
чем больше выбор → тем выше вероятность покупки, ведь каждый найдёт что-то под себя.

Сценарий 1 — «много выбора» (24 вида джема)

• около 60% проходящих останавливались у стенда
• людям было интересно смотреть большой ассортимент
• но купили джем лишь 3% из подошедших



Эксперимент с джемом

Сценарий 2 — «мало выбора» (6 видов джема)

- остановилось меньше людей — около 40%
- ассортимент выглядел менее «вау»
- **но джем купили уже 30% людей!**

Большой выбор
✓ сильнее привлекает внимание
✗ усложняет выбор
✗ снижает вероятность покупки

Маленький выбор
✗ выглядит менее впечатляюще
✓ упрощает решение
✓ повышает конверсию



Что такое рекомендательные системы?

Рекомендательная система — это алгоритм, который помогает пользователю найти наиболее релевантные объекты среди большого количества доступных вариантов.

Насколько они вообще эффективны?

35%

покупок в Amazon
сделаны из рекомендаций

80%

фильмов в Netflix
смотрят из рекомендаций

70%

видео на YouTube
смотрят из рекомендаций

Ключевые определения

Ключевые элементы рекомендательной системы:

пользователи
клиенты, покупатели, пациенты, соискатели



объекты
товары, фильмы, музыка, лекарства, вакансии



Основные типы рекомендаций

1 «Неперсонализированные»

общие для всех подходы:
хиты продаж, новинки, тренды



327 ₽ 550 ₽
ЕЛИЗАР / 1 кг Кислородный пятновыв...
4,9 · 1 237 547 оценок

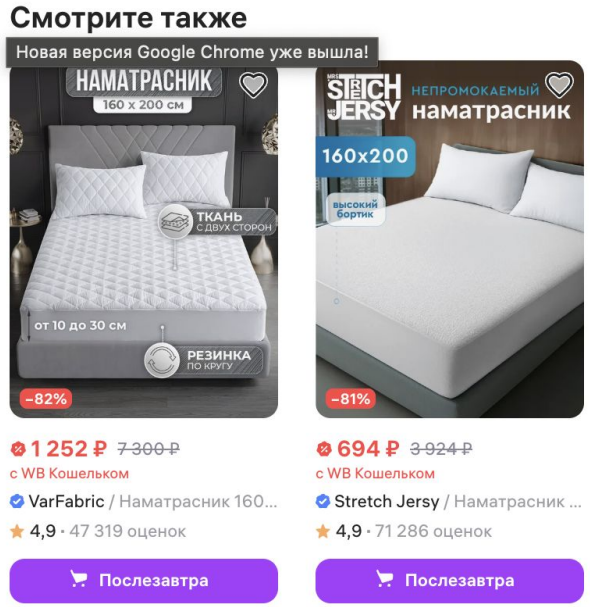
2 «Персонализированные»

пользователь → объекты,
индивидуальный подход



3 «Объектные»

объект → объект,
похожие или сопутствующие



1 252 ₽ 7 300 ₽
с WB Кошельком
VarFabric / Наматрасник 160...
4,9 · 47 319 оценок
Послезавтра

694 ₽ 3 924 ₽
с WB Кошельком
Stretch Jersy / Наматрасник ...
4,9 · 71 286 оценок
Послезавтра

Где какие рекомендации разместить?

Технические требования:

персональные — нужно знать конкретного пользователя (его ID)	**на главных страницах сайтов, в ЛК**
объектные — нужно знать товар-якорь, к которому строим рекомендации (его ID)	**на страницах товаров/фильмов, после просмотра или покупки**
неперсонализированные — ничего не нужно	**где угодно (но качество страдает)**

Также можно замешивать типы рекомендаций под сценарий: например, сопутствующие к недавним покупкам, похожие на последние запросы…

02

Обзор основных подходов и алгоритмов

Форматы построения рекомендаций

Оффлайн
рассчитываем ТОП-продаж или интересы пользователей ML-моделями по историческим данным и показываем эти рекомендации до следующего пересчёта.

Онлайн
«на лету» подхватываем самые последние намерения пользователей — сюда как раз идеи про смешивание объектных и персональных рекомендаций.

НО!

Онлайн-режим требует больше инфраструктурных ресурсов (RAM, CPU, GPU) и чувствительнее к сбоям и падениям.

Рекомендуется использовать как улучшение поверх оффлайн-рекомендаций.

Данные для построения рекомендаций

1

Коллаборативные данные (просмотры, клики, покупки, лайки)

← наиболее эффективны

Воронка продаж для интернет-магазина



Просмотр

Клик

Отправление товара в корзину

Переход на страницу оплаты

Оформление заказа

Данные для построения рекомендаций

2

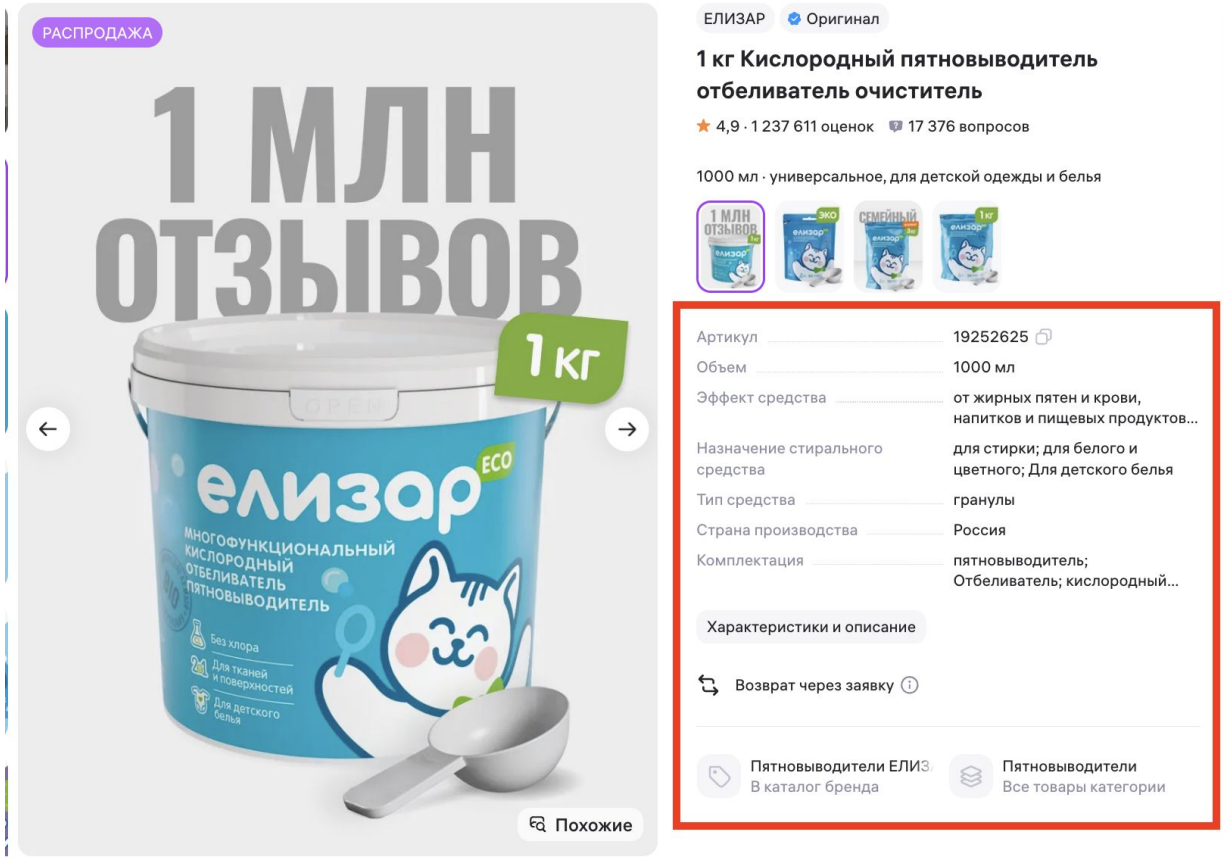
Метаданные по пользователям (пол, возраст, география проживания, опросы)



Данные для построения рекомендаций

3

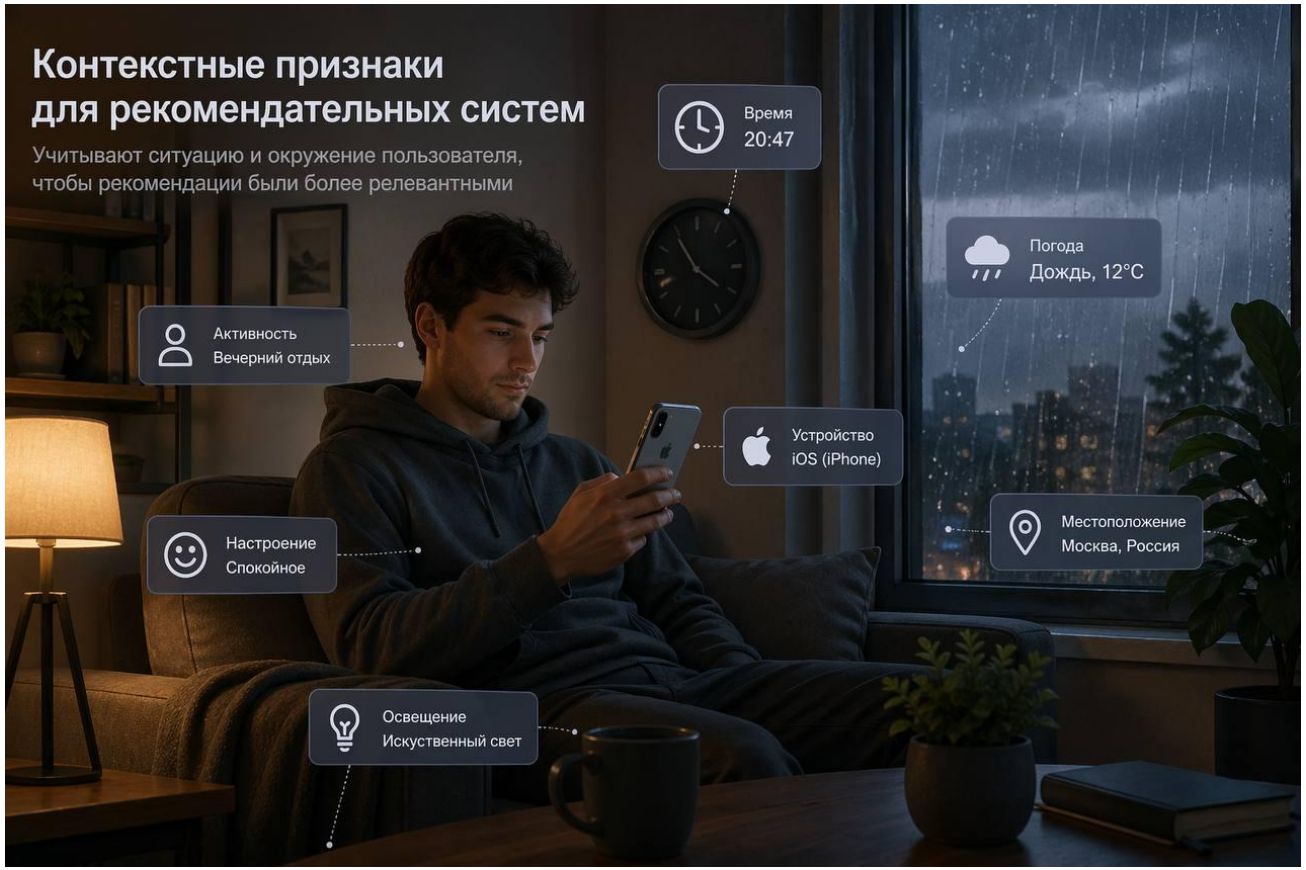
Метаданные по объектам (цвет и цена товара, жанр и тематика фильма)



Данные для построения рекомендаций

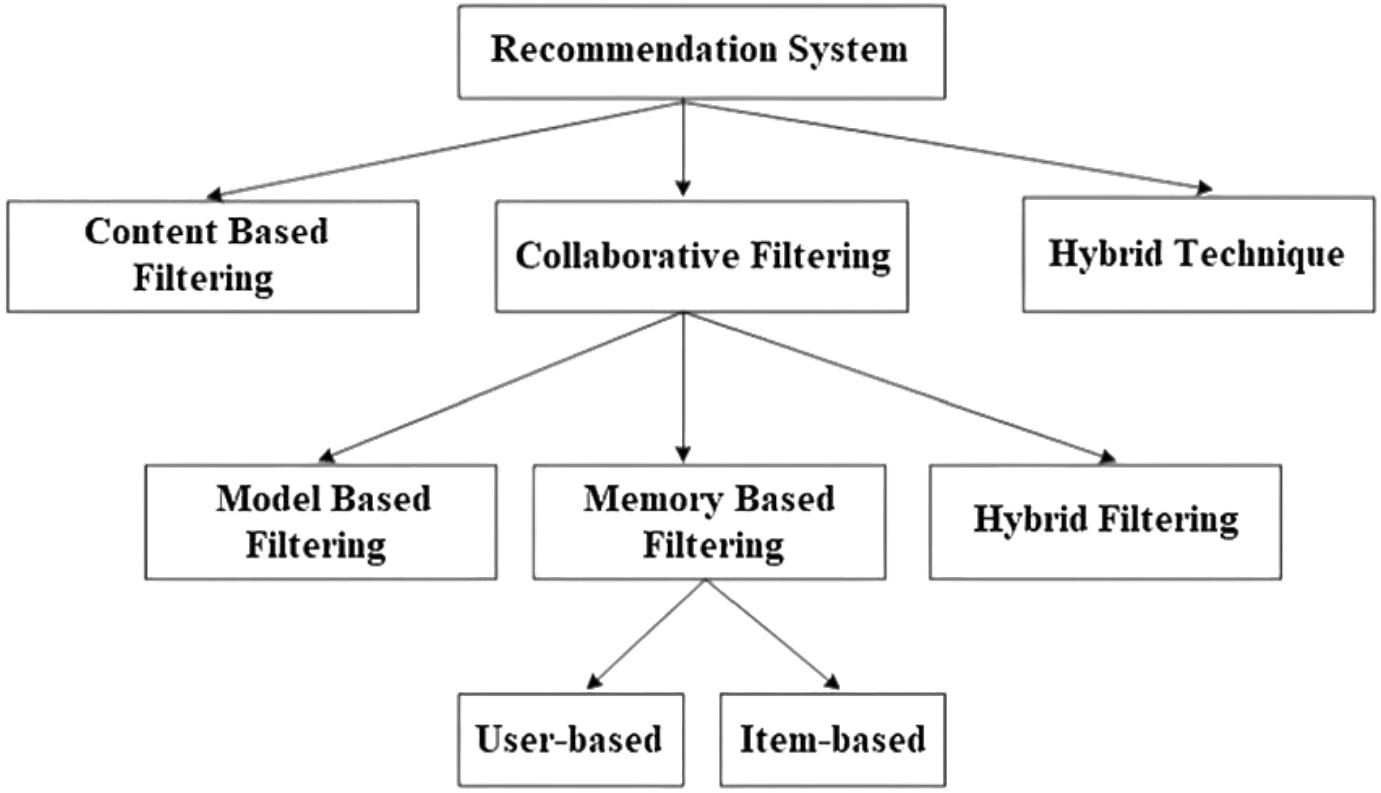
4

Контекстные признаки
(время, устройство, погода и т.п.)



Алгоритмы для построения рекомендаций

Часто разделение сводится к тому, какие данные у нас есть



Свойства объектов



ЕЛИЗАР · Оригинал

1 кг Кислородный пятновыводитель отбеливатель очиститель

★ 4,9 · 1 237 611 оценок · 17 376 вопросов

1000 мл · универсальное, для детской одежды и белья

Артикул	19252625
Объем	1000 мл
Эффект средства	от жирных пятен и крови, напитков и пищевых продуктов...
Назначение стирального средства	для стирки; для белого и цветного; Для детского белья
Тип средства	гранулы
Страна производства	Россия
Комплектация	пятновыводитель; Отбеливатель; кислородный...

Характеристики и описание

Возврат через заявку

Пятновыводители ЕЛИЗ
В каталог бренда

Пятновыводители
Все товары категории

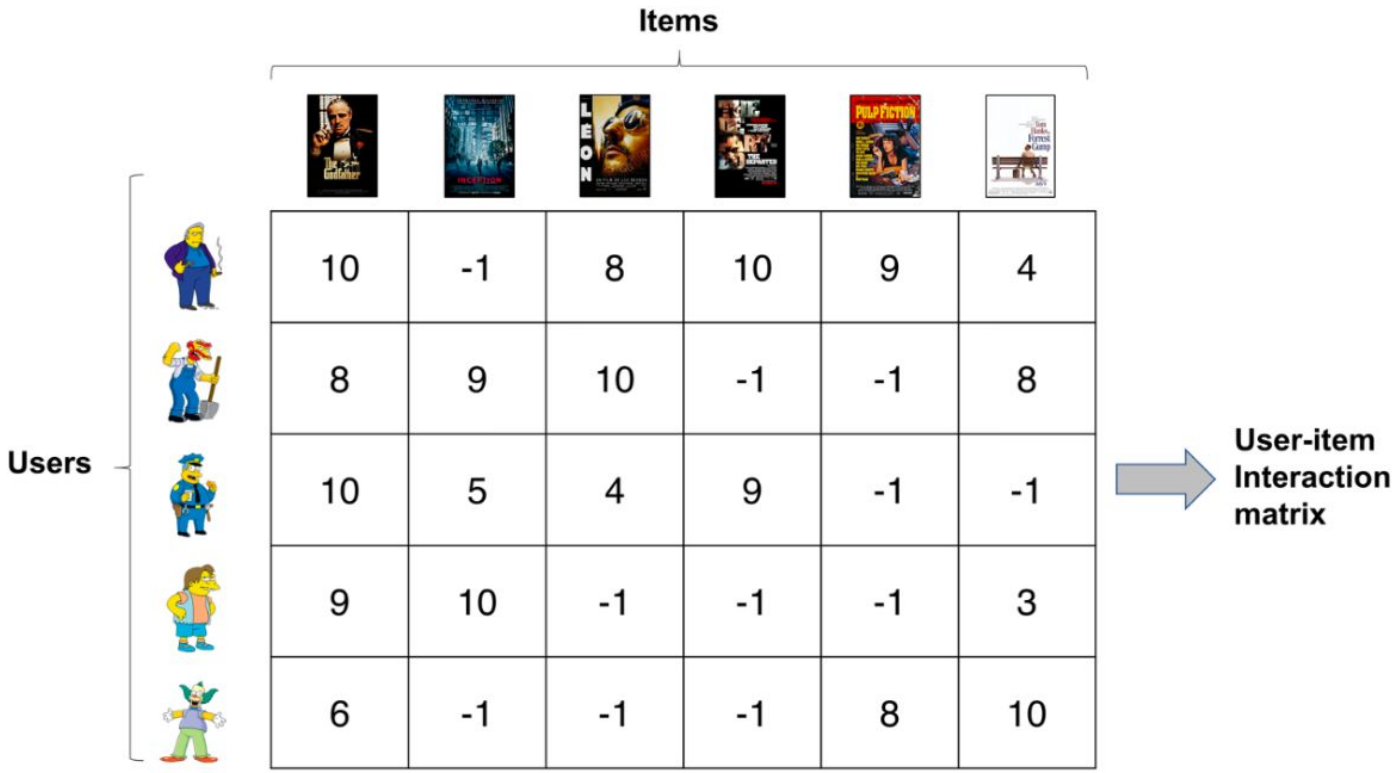
Что используем:

- картинка / видео
- описание и характеристики

MVP — наиболее похожие по характеристикам.

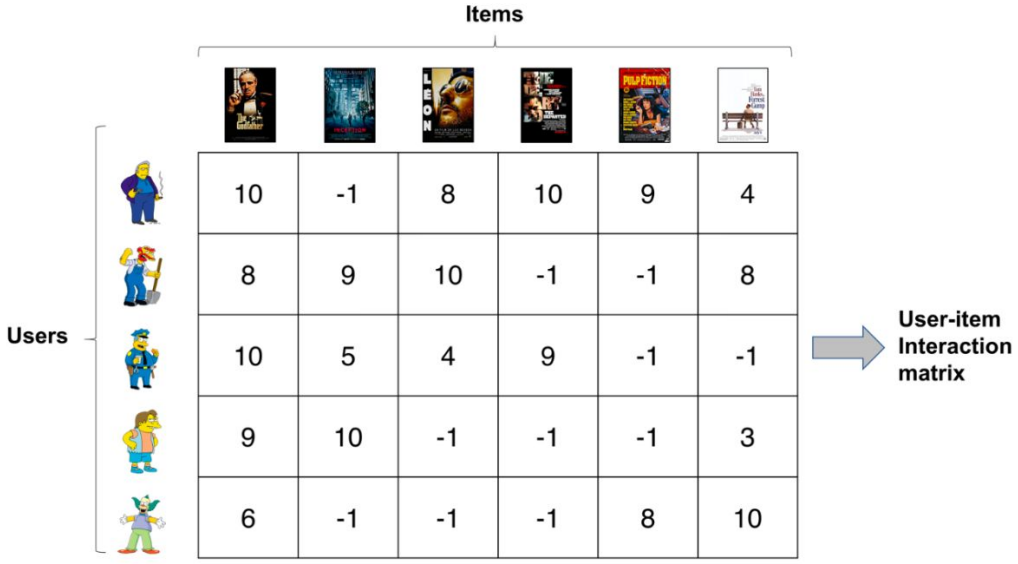
Лучше — модели CV и NLP.

Матрица «пользователь-объект»

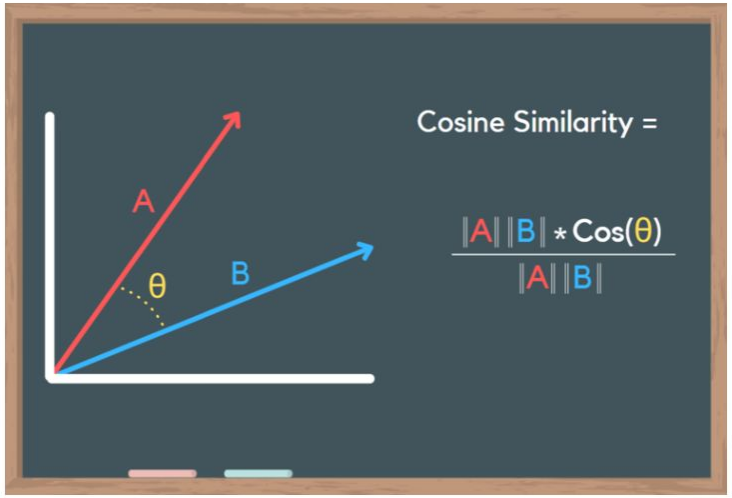


Из коллаборативных данных формируем матрицу взаимодействий «пользователь-объект».

Коллаборативная фильтрация



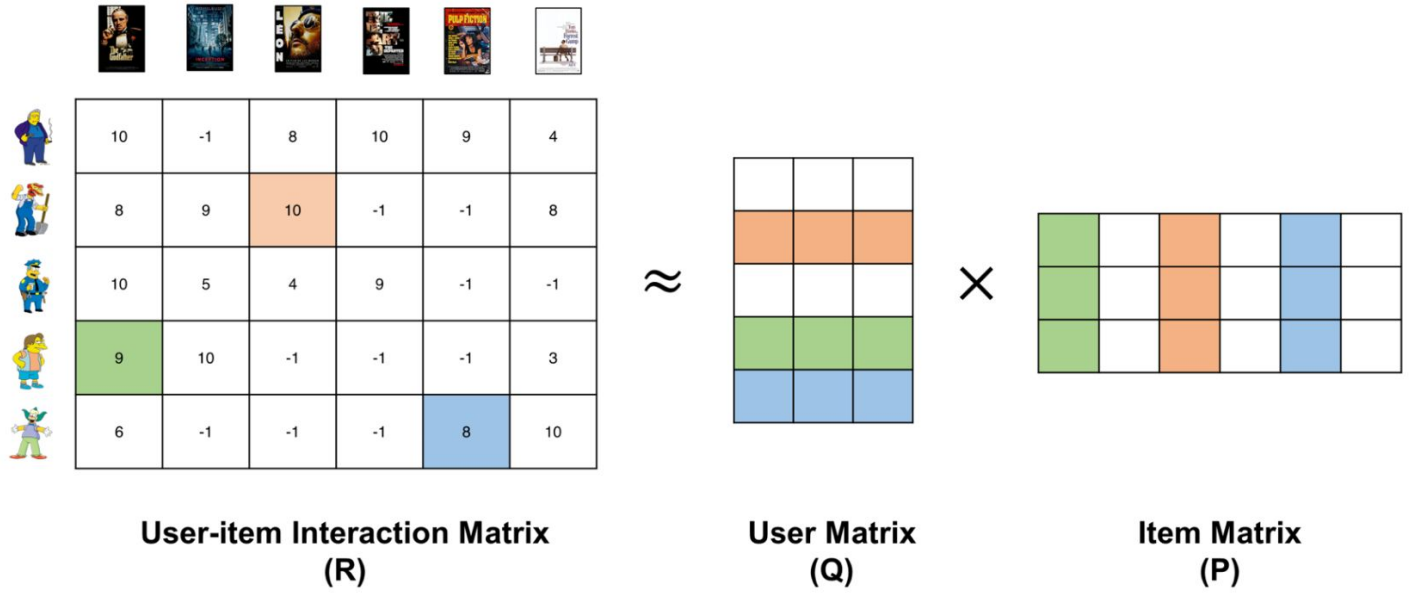
10	-1	8	10	9	4
8	9	10	-1	-1	8
10	5	4	9	-1	-1
9	10	-1	-1	-1	3
6	-1	-1	-1	8	10



Ищем ближайшие векторы из геометрии!

Минусы: длинные векторы, никакого ML.

Матричная факторизация

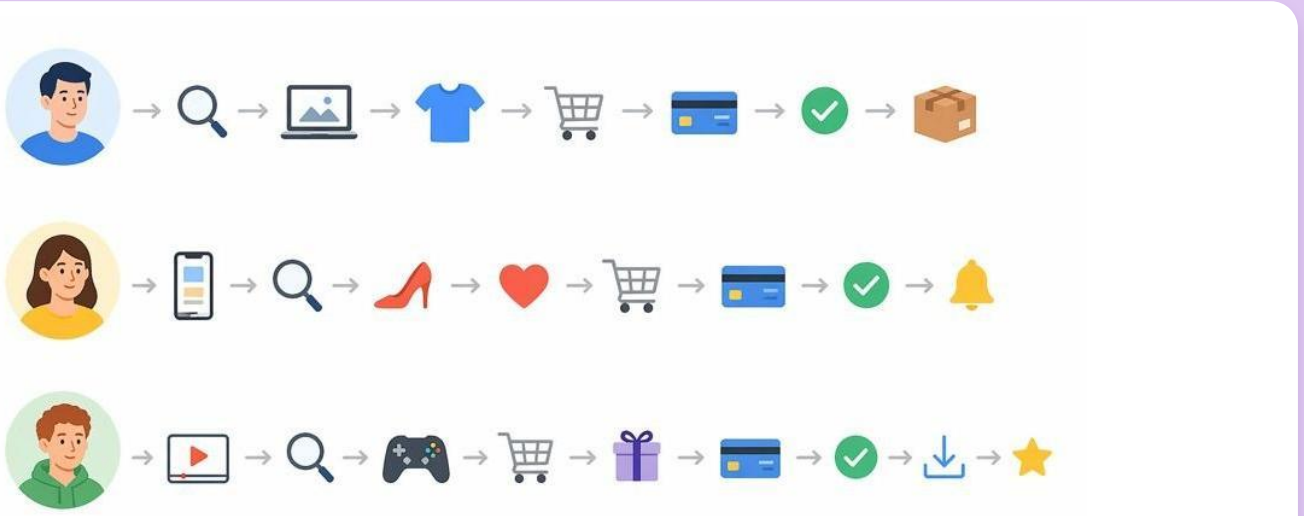


Раскладываем матрицу взаимодействий на две: скрытых факторов пользователей и скрытых факторов объектов.

Минус: действия не учитываются во времени.

Модели на последовательностях

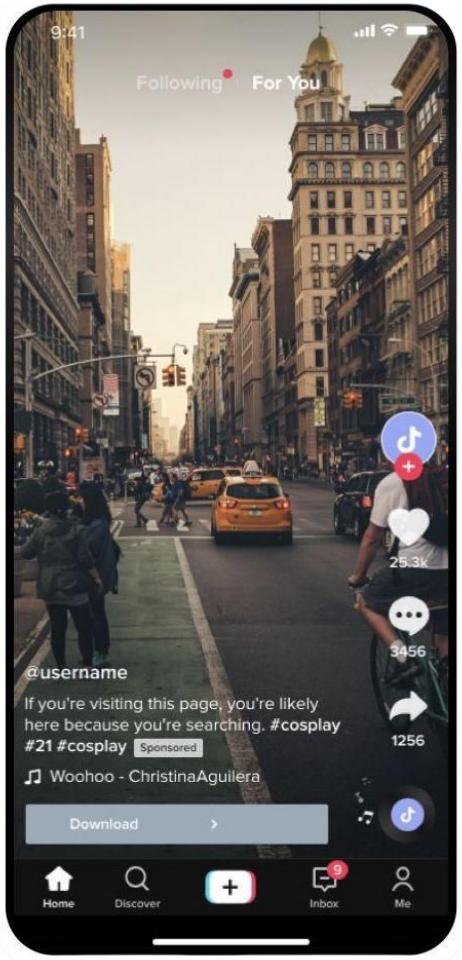
Идеи из NLP (обработки текстов):
пользователь == последовательность его действий
предложение == последовательность слов

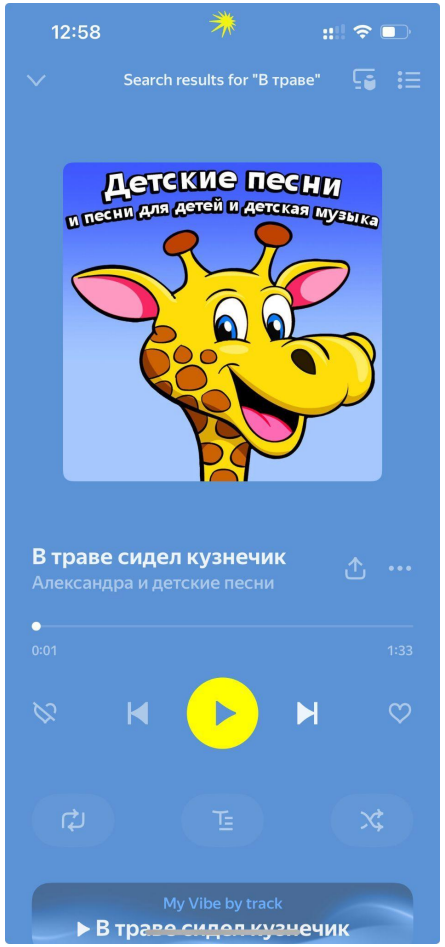


Мгновенный учёт явной обратной связи

Системы подстраиваются в реальном времени под вашу обратную связь — от простого показа похожих до RL-методов.

Наиболее актуально для стриминговых платформ с «коротким» контентом.





Как оценивать качество?

Онлайн-оценка

A/B-тест на реальных пользователях

+ более достоверная проверка

− дорого, долго, больше рисков

Оффлайн-оценка

выбираем лучшую ML-модель по историческому поведению пользователей

+ простая и дешёвая проверка

− не знаем, как рексистема повлияет на пользователей

Один из «вызовов» рексистем — найти корреляцию между оффлайн- и онлайн-метриками

Примеры оффлайн-оценок

Precision@k — доля рекомендованных объектов, которая действительно релевантна пользователю.

$$\text{Precision@K} = \frac{|\text{Rel}_u \cap \text{Rec}_u^K|}{K}$$

Rel_u — релевантные (купленные, просмотренные) объекты;
Rec_u^K — K рекомендованных пользователю объектов.



Примеры онлайн-оценок

GMV	сумма всех совершённых покупок
Orders	число успешных заказов
AOV	GMV / Orders — средний чек
CR	Orders / Users — доля пользователей, совершивших целевое действие
CTR	Clicks / Views — доля пользователей, кликнувших на рекомендацию

03

Проблемы и кейсы в рекомендациях

Вечные проблемы рекомендательных систем

1 Холодный старт

ничего не знаем про новых пользователей — как собрать им персональные рекомендации?

2 Простор для творчества

начиная от дизайна, заканчивая алгоритмами

3 Рекомендации меняют поведение

без A/B не понять реальный эффект, и он бывает неожиданным

4 Шумные и разреженные данные

особенно когда каталоги большие

5 Feedback loop

учимся на том, что сами порекомендовали → новые товары не попадают в выдачу

6 Масштабируемость

больше пользователей, онлайн-рекомендации, бесконечные ленты

7 Пользователь ≠ продавец ≠ маркетплейс

у каждого свои интересы — как угодить всем?

8 Меняющийся каталог

e-commerce, стриминговые платформы и т.п.

Спасибо за внимание!

Время вопросов!

Мария Жарова
Team Lead ML Wildberries & Russ

